# Abgabe Effiziente Programme WS22/23

Sie können ein beliebiges Beispiel wählen.

Wer nichts anderes vorhat, kann die unten vorgegebene Aufgabe für dieses Semester wählen.

Natürlich können Sie, wenn Sie wollen, auch die Implementierung eines anderen Problems optimieren; allerdings hat das einige Nachteile: Sie müssen einen Teil der Zeit Ihrer Präsentation für die Erklärung des Problems und des Algorithmus aufwenden, und die Ergebnisse sind nicht direkt vergleichbar. Der Vorteil (vor allem, wenn Sie einen späteren Termin wählen) ist, dass Sie nicht das wiederholen, was andere gemacht haben, oder ein langsameres Programm präsentieren.

Bereiten Sie eine 18-minütige Präsentation vor (am besten machen Sie einen Probelauf, damit sich die Präsentation auch sicher in der Zeit ausgeht). Da Sie dabei nicht soviel Zeit haben wie ich in der Vorlesung, präsentieren Sie die meisten Schritte nur im Überblick (also eventuell nur, wieviel er gebracht hat), und nur ein paar besonders interessante Schritte mit mehr Details. Besonders interessant sind u.a. die Schritte, die unerwartet viel oder wenig bringen.

## Vorgegebene Aufgabe: Ramanujan-Zahlen

### Hintergrund

Ramanujan-Zahlen sind Zahlen, die auf mehrere Arten als Summen zweier Kubikzahlen dargestellt werden können.

### Genaue Aufgabe

Die beiden <u>vorgegebenen Programme</u> (ramasort und ramanujan) zählen die Ramanujan-Zahlen bis zu einer bestimmten Grenze n, indem sie alle Kandidaten-Zahlen i^3+j^3<=n (wobei i<j) erzeugen und dann durch Sortierung (ramasort) oder eine Hash-Tabelle (ramanujan) herausfinden, ob dieselbe Zahl mehrmals vorkommt.

Wenn Sie make aufrufen, wird per default ramasort compiliert und dann mit einem Speicherlimit von 100MB und N=10^13 gemessen (wobei das Speicherlimit in diesem Fall zu einem Segmentation Fault führt). Man kann bei Aufruf von make die entsprechenden Parameter übergeben:

Parameter Default
MEMORY 1024000 (100MB)
N 10000000000000 (10^13)
RAMA ramasort
CC gcc
CFLAGS -0 -Wall

Z.B. kann man ramanujan mit knapp 9GB wie folgt laufen lassen:

```
make RAMA=ramanujan MEMORY=9000000
```

Die beiden Programme geben (wenn sie genügend Speicher haben) folgende Zeile (für n=10^13) aus:

114359 Ramanujan numbers up to 1000000000000, checksum=355033384379411459

Ihr Programm muss für jedes n diese Zeile genauso ausgeben wie eines der vorgegebenen Programme (wenn die mit genug Speicher gestartet werden).

Zusätzlich geben die vorgegebenen Programme noch Informationen über ihre internen Datenstrukturen und eine Untergrenze für den Speicherverbrauch aus (wobei ramasort mit n=10^13 und MEMORY=4000000 zwar funktioniert, aber deutlich langsamer ist als bei MEMORY=9000000; offenbar muss die Sortierfunktion qsort() mehr arbeiten, wenn der Speicher knapp ist); diese zusätzlichen Ausgaben muss Ihr Programm nicht machen bzw. darf es andere zusätzliche Ausgaben machen.

Hier die Laufzeiten auf der g0 für die beiden Programme mit MEMORY=9000000:

Performance counter stats for 'ramasort 100000000000000':

```
120074048548 cycles
207077932729 instructions # 1.72 insn per cycle
606189276 branch-misses
58956280 LLC-load-misses
158296196 LLC-store-misses

25.854830070 seconds time elapsed

24.468421000 seconds user
1.384023000 seconds sys
```

Performance counter stats for 'ramanujan 100000000000000':

```
99013672697 cycles
57773078853 instructions # 0.58 insn per cycle
131312766 branch-misses
415725921 LLC-load-misses
125359064 LLC-store-misses
31.283403372 seconds time elapsed
29.152750000 seconds user
2.119763000 seconds sys
```

Hier sieht man, dass der große Speicherverbrauch auch zu nennenswerten System-Zeiten (zum Löschen des Speichers) führt. Die LLC-Misses tragen viel bei, bei ramanujan offenbar den größten Teil der Zeit (bei 50ns/LLC-load-miss machen die LLC-load-misses schon 20.79s aus).

Ein eigenartiges Verhalten der g0 ist, dass sie bei ramasort zwar in der Nähe der 4,7GHz Taktfrequenz landet, die auf dieser Maschine scheinbar das Maximum sind (offiziell kann der Prozessor 5,1GHz, ich habe aber bisher nur 4,7GHz gesehen), bei ramanujan aber nur mit ca. 3,2GHz läuft. Daher reicht es in diesem Fall nicht, für das Ziel Prozessor-Zeit-Effizienz auf die Zyklen zu schauen, sondern man muss auf die Summe von "user" und "sys"-Zeit schauen ("elapsed" ist bei leerer Maschine nahe dran, kann aber steigen, wenn alle Kerne ausgelastet sind). Auf der g0 ist SMT/Hyperthreading abgeschaltet, um besser reproduzierbare Messwerte zu bekommen.

Hier ein paar Ideen für algorithmische Verbesserungen, die sie verfolgen können, aber nicht müssen (und insbesondere können Sie auch eigene ideen verfolgen).

- Teilen des Gesamtbereichs 1..n in Abschnitte, in denen jeweils eine genügend kleine Zahl von Kandidaten drinnen sind, um mit dem Speicherlimit auszukommen. Wenn die Abschnitte klein genug für z.B. den LLC-Cache (16MB) sind, sollten die LLC misses deutlich reduziert werden.
- Eine andere Organisation der Hash-Tabelle von ramanujan, die zu weniger Speicherzugriffen und daher weniger misses führt; immerhin werden nur ca. 205M Kandidaten untersucht, da sind 415M LLC-loadmisses >2 misses pro Kandidat im Durchschnitt.
- Man hat nur eine Tabelle mit maximal cbrt(n/2) Elementen (17100 bei n=10^13), in der für jedes i ein j und sum=i^3+j^3 steht. Und zwar steht das minimale j, sodass sum mindestens so gross ist wie der letzte angeschaute Kandidat. In jedem Schritt wird der Tabelleneintrag mit dem kleinsten sum gefunden, und für diesen Eintrag j erhöht und die zugehörige sum ausgerechnet. Wenn es mehrere Einträge mit der selben sum gibt, hat man wieder eine Ramanujan-Zahl gefunden. Eine möglicherweise geeignete Datenstruktur dafür ist der Heap.
- (Nicht wirklich algorithmisch:) qsort() ist zwar eine angenehme Funktion, aber das Interface mit dem Aufruf der Vergleichsfunktion ist nicht sonderlich effizient. Sie können vielleicht durch Schreiben einer spezialisierten Sortierfunktion effizienter werden.

Sie sollten hier aber nicht alle Ideen verfolgen (die ja teilweise in völlig verschiedene Richtungen gehen), sondern sich eine Kombination vielversprechender Ideen überlegen, implementieren, und dann diese Implementierung optimieren; überlassen Sie die anderen Richtungen Ihren Kollegen. Sie können z.B. das Teilen des Gesamtbereichs als einen Optimierungsschritt darstellen (auch wenn's vor allem ein notwendiger funktionaler Schritt ist, wenn man beim Sortieren oder der Hash-Tabelle bleibt), die spezialisierte Sortierfunktion als einen weiteren.

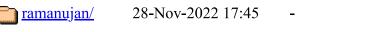
Sie können Ihr Programm (und Doku dazu, z.B. Ihre Präsentation) im Web veröffentlichen (wird nicht beurteilt), und zwar indem Sie auf /nfs/unsafe/httpd/ftp/pub/anton/lvas/effizienz-abgaben/2022w eine Web-Page (vielleicht mit einem Link zu einem Projekt auf Sourcehut oder Github) oder ein Verzeichnis mit Ihren Dateien anlegen.

#### **Anton Ertl**

Name Last modified Size Description



<u>ramanujan.tar.gz</u> 28-Nov-2022 20:12 1.7K



Apache/2.2.22 (Debian) DAV/2 mod\_fcgid/2.3.6 PHP/5.4.36-0+deb7u3 mod\_python/3.3.1 Python/2.7.3 mod\_ssl/2.2.22 OpenSSL/1.0.1e mod\_perl/2.0.7 Perl/v5.14.2 Server at www.complang.tuwien.ac.at Port 443